

UNIVERSIDADE ESTADUAL DE CAMPINAS – UNICAMP
INSTITUTO DE MATEMÁTICA, ESTATÍSTICA E COMPUTAÇÃO CIENTÍFICA – IMECC

Disciplina: ME607 - Séries Temporais
Professor: Aluísio de Souza Pinheiro

Modelagem da Qualidade do Ar (PM2.5) em Pequim

Projeto 2: Análise de Séries Temporais

Autor:
Eduardo Saegi de Souza Hsu
RA: 277142

CAMPINAS
2026

1 Introdução

A poluição atmosférica é um desafio de saúde pública global, e a China enfrentou crises severas de qualidade do ar devido ao seu rápido processo de urbanização (2). A concentração de material particulado fino (PM2.5) em Pequim atingiu níveis críticos no início da última década, impulsionada pela queima de carvão no inverno e condições meteorológicas adversas.

A partir de 2013, políticas governamentais resultaram em melhorias graduais na qualidade do ar (2). Compreender a dinâmica dessa transição exige ferramentas analíticas robustas.

1.1 Objetivos e Ciclo Metodológico

O objetivo deste trabalho é modelar a série temporal diária de concentração de PM2.5 em Pequim, fornecendo um modelo estatístico preditivo. Para garantir o rigor analítico, a pesquisa adota a metodologia de Box-Jenkins estruturada no seguinte ciclo:

1. **Análise Exploratória:** Avaliação da série bruta, sazonalidade e testes de estacionariedade;
2. **Transformação:** Estabilização da variância para adequação aos pressupostos lineares;
3. **Identificação:** Análise correlográfica teórica para definição de processos geradores;
4. **Estimação:** Ajuste concorrente de modelos ARMA e seleção objetiva via AIC;
5. **Diagnóstico:** Verificação formal de independência, normalidade e heterocedasticidade condicional;
6. **Previsão:** Validação cruzada quantitativa fora da amostra e análise de cobertura empírica.

2 Análise Descritiva e Exploratória

A análise inicial indica a presença de eventos extremos. As estatísticas descritivas básicas da série diária de PM2.5 estão na Tabela 1.

Tabela 1: Estatísticas Descritivas - Concentração de PM2.5

Métrica	**Valor**
Média	98,65
Desvio Padrão	77,55
Assimetria (Skewness)	1,619
Curtose	6,411

A série apresenta forte assimetria à direita (1,619) e curtose acentuada (6,411), indicando uma distribuição de caudas pesadas (3). Isso sugere que eventos de alta toxicidade são frequentes.

A série temporal (Figura 1) sugere a presença de heterocedasticidade, com agrupamentos irregulares de volatilidade. O histograma e a densidade (Figura 2) confirmam o desvio da normalidade.

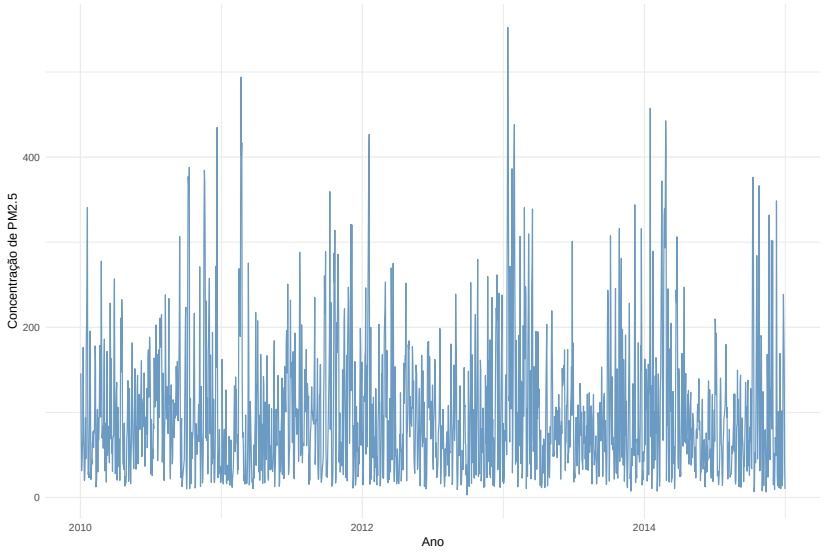


Figura 1: Evolução diária da concentração de PM2.5 evidenciando agrupamentos de volatilidade.

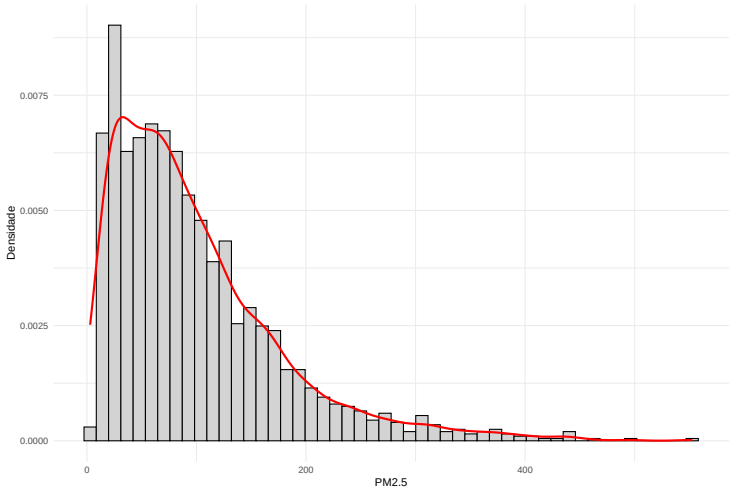


Figura 2: Histograma e curva de densidade evidenciando assimetria à direita e não normalidade.

O teste de Dickey-Fuller Aumentado (ADF) rejeitou a hipótese de raiz unitária na série bruta (Estatística = -10,136, $p < 0,01$). O resultado é compatível com a ausência de comportamento de passeio aleatório.

A análise do boxplot mensal (Figura 3) demonstra que a variabilidade não é homogênea. No inverno, observa-se elevação simultânea do nível médio e da variância interquartílica (2).

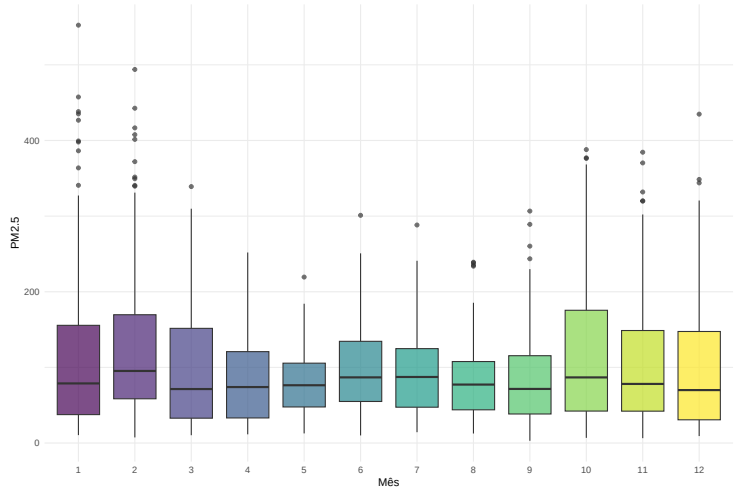


Figura 3: Sazonalidade mensal via Boxplot evidenciando elevação de nível e variância no inverno.

A decomposição clássica STL (Figura 4) isola essas forças. A tendência (*trend*) captura o declínio consistente entre 2013 e 2014. O componente residual expõe resíduos com picos acentuados, sugerindo a presença de variabilidade residual relevante.

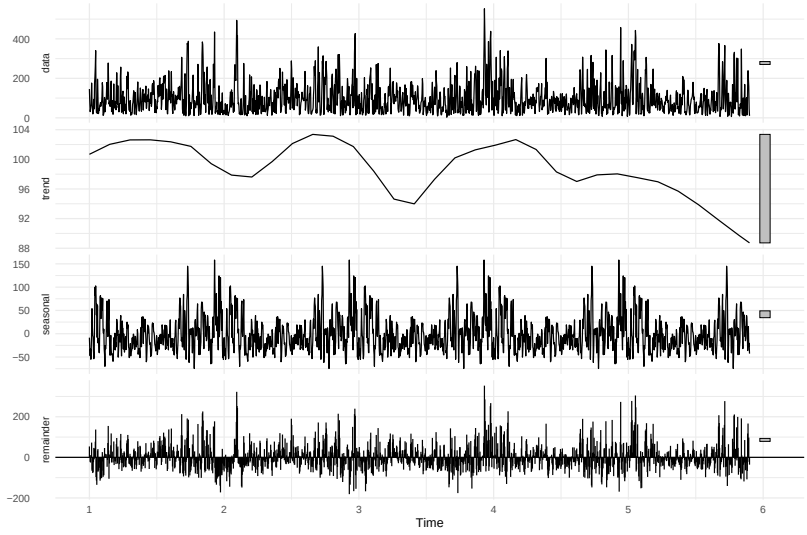


Figura 4: Decomposição Clássica STL da série temporal.

3 Transformações Estabilizadoras

Embora a série não apresente evidências de raiz unitária, sua variância mostrou-se instável (3). Aplicou-se a transformação logarítmica, que estabilizou as estimativas locais de variância e mitigou o impacto matemático de eventos extremos (Figura 5).

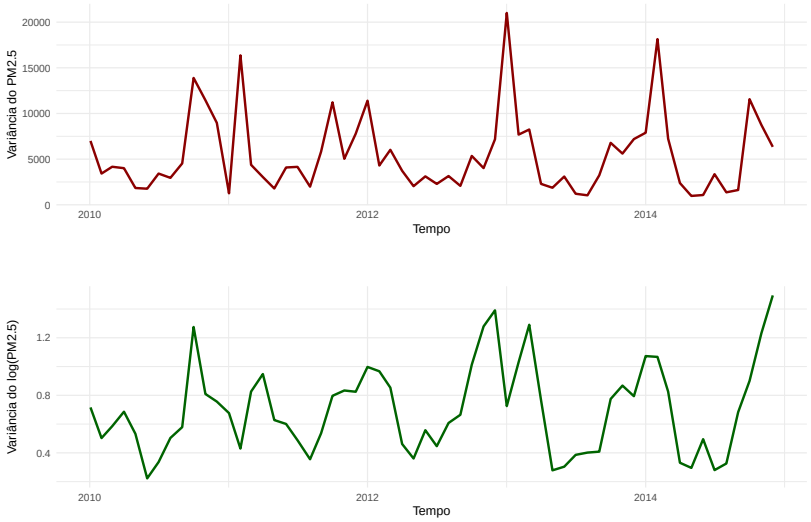


Figura 5: Comparação da variabilidade mensal: Série bruta superior vs. Série logarítmica inferior.

Um novo teste ADF confirmou a ausência de evidências de raiz unitária na série transformada ($p = 0,01$). Consequentemente, optou-se por não aplicar a primeira diferença ($d = 0$). Diferenciar uma série já estacionária pode introduzir dependências artificiais no componente de médias móveis (fenômeno de superdiferenciação) (3). A modelagem seguiu apenas com a série no nível logarítmico.

4 Identificação e Seleção de Modelos

A inspeção dos correlogramas (Figura 6) revelou decaimento gradual na Função de Autocorrelação (FAC), com defasagens significativas ultrapassando as bandas de confiança teóricas. A Função de Autocorrelação Parcial (FACP) apresentou picos significativos, especialmente nos lags 1 e 2. Esse comportamento misto sugere a adequação de modelos Autorregressivos e de Médias Móveis (ARMA) combinados.

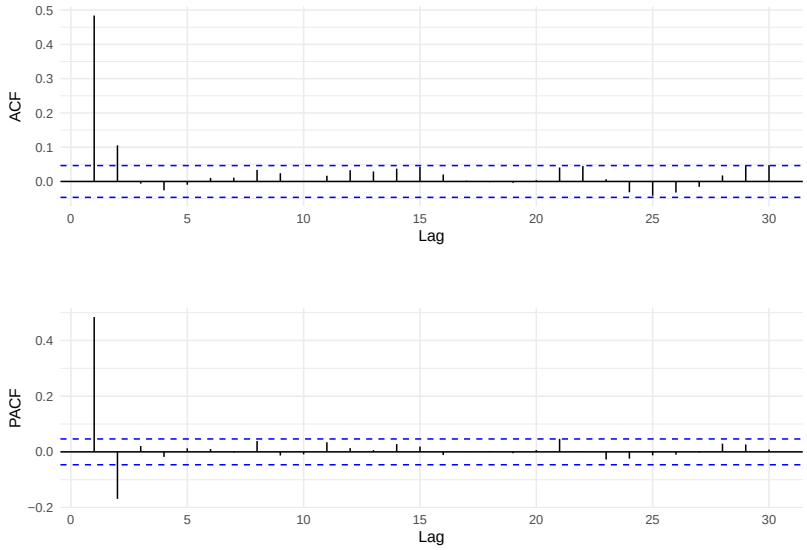


Figura 6: Funções de Autocorrelação (FAC) e Autocorrelação Parcial (FACP) da série logarítmica.

Para a seleção do modelo, procedeu-se com a estimação concorrente. As ordens candidatas foram balizadas pelos truncamentos e decaimentos observados na FAC e FACP, restringindo-se a estruturas de baixa complexidade para preservar o princípio da parcimônia. Avaliou-se também um modelo SARIMA com transformadas de Fourier ($s = 365$) para testar a inclusão da sazonalidade longa.

Tabela 2: Comparação de Modelos pelo Critério de Informação de Akaike (AIC)

Modelo	**AIC**
AR(2)	3809,788
ARMA(1,1) - Modelo Selecionado	**3810,379**
MA(3)	3811,288
ARMA(2,2)	3812,536
ARMA(1,1) com Fourier Sazonal	3813,199

Embora o modelo AR(2) tenha apresentado o menor AIC, a diferença inferior a 2 unidades indica equivalência empírica entre os modelos (1). Optou-se pelo ARMA(1,1) por sua maior coerência com o padrão misto sugerido pelos correlogramas FAC e FACP. Além disso, ambos os parâmetros do ARMA(1,1) mostraram-se altamente significativos. Embora a sazonalidade invernal exista empiricamente, sua

contribuição marginal na redução do erro após a transformação logarítmica foi insuficiente para compensar a penalização de complexidade imposta pelo AIC, resultando no descarte da parametrização harmônica sazonal. Ademais, os diagnósticos residuais dessa abordagem multissazonal não apresentaram melhorias estruturais que justificassem a perda de graus de liberdade.

Tabela 3: Estimativas e Significância dos Parâmetros do Modelo ARMA(1,1)

Parâmetro	**Estimativa**	**Erro Padrão**	**Estatística** z	**Valor-**p
AR(1) (ϕ_1)	0,2488	0,0421	5,904	$< 0,001$
MA(1) (θ_1)	0,3215	0,0406	7,902	$< 0,001$
Intercepto (c)	4,3025	0,0291	147,757	$< 0,001$

Os coeficientes apresentaram significância estatística ($p < 0,001$), refutando a hipótese nula de parâmetros iguais a zero.

5 Diagnóstico do Modelo ARMA(1,1)

Todos os testes diagnósticos conduzidos nesta seção adotaram o nível de significância de 5% ($\alpha = 0,05$).

Os resíduos não apresentaram autocorrelação linear significativa (Figura 7). O teste de Ljung-Box não rejeitou a hipótese de independência linear ($\chi^2 = 6,5147$, $p = 0,7703$), indicando que a média condicional foi modelada adequadamente.

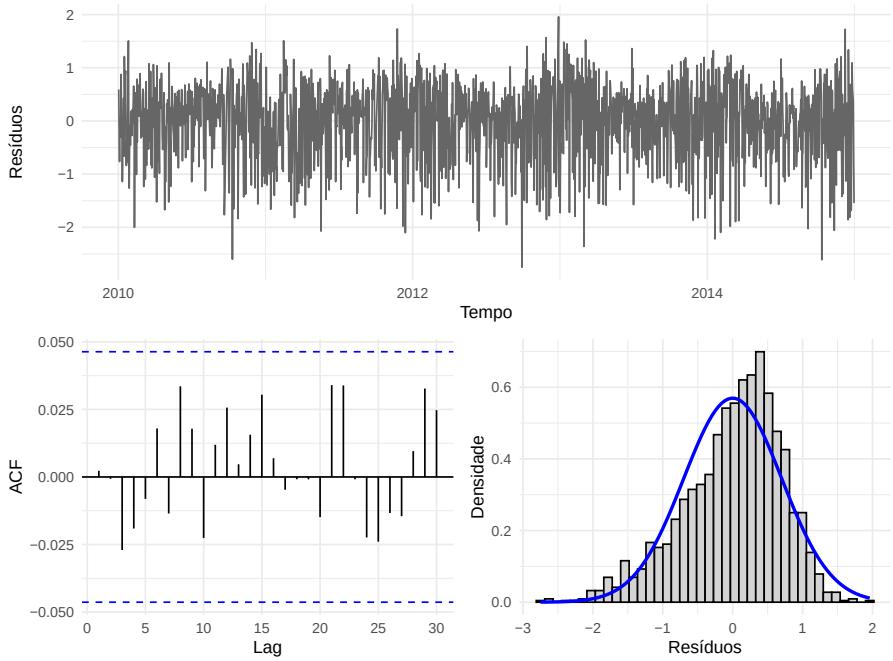


Figura 7: Painel de diagnóstico do modelo ARMA(1,1) evidenciando resíduos linearmente independentes.

Contudo, o modelo apresentou limitações quanto à distribuição e à variância dos resíduos. O teste de Jarque-Bera rejeitou a hipótese de normalidade ($\chi^2 = 135,29$, $p < 0,001$), confirmando o excesso de curtose. A FAC dos resíduos ao quadrado (Figura 8) indicou dependência estrutural remanescente na variância.

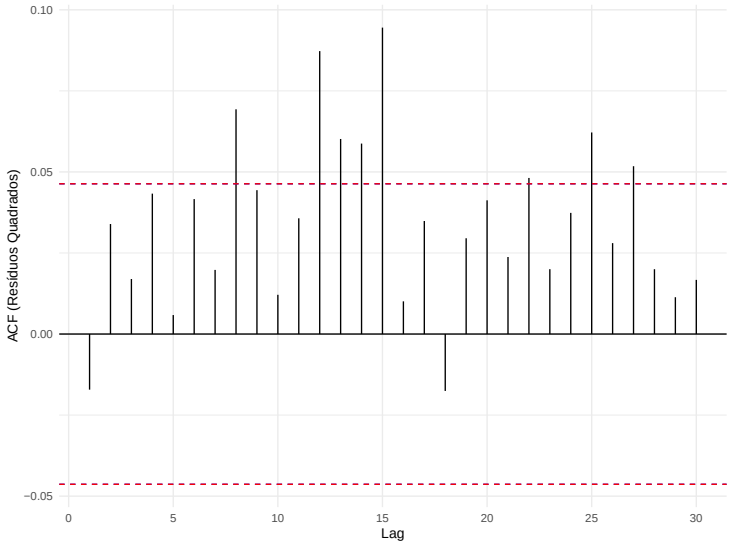


Figura 8: FAC dos resíduos quadráticos sugerindo efeito ARCH.

Para uma avaliação formal da heterocedasticidade condicional utilizou-se o teste ARCH-LM de Engle (Tabela 4).

Tabela 4: Teste Formal de Heterocedasticidade Condicional nos Resíduos

Teste	**Estatística χ^2**	**Graus de Liberdade**	**Valor-p**
ARCH-LM (Engle)	21,152	10	0,02006

A rejeição da hipótese nula atesta a presença do efeito ARCH. O modelo ARMA(1,1) não conseguiu capturar adequadamente a heterocedasticidade observada na série.

6 Validação Cruzada e Previsão

Para avaliar o desempenho preditivo fora da amostra, realizaram-se previsões em um horizonte de 15 dias no verão (Julho/2014) e no inverno (Janeiro/2014), ilustradas na Figura 9.

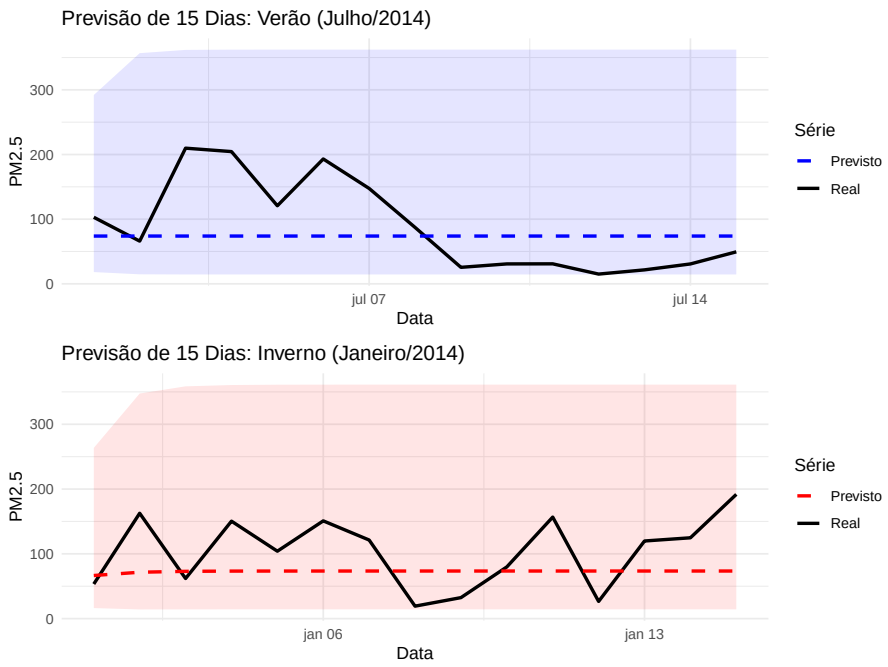


Figura 9: Previsão de 15 dias de Backtesting no Verão e Inverno.

A extração das métricas quantitativas consta na Tabela 5.

Tabela 5: Desempenho Preditivo e Empírico Fora da Amostra (Horizonte de 15 dias)

Cenário (Ano de 2014)	**RMSE** ($\mu g/m^3$)	**MAE** ($\mu g/m^3$)	**Cobertura do IC (95%)**
Verão (Julho)	69,83	57,97	100%
Inverno (Janeiro)	61,27	53,06	100%

O intervalo de confiança de 95% teórico apresentou uma cobertura empírica de 100% em ambos os cenários. Em séries de alta volatilidade, uma cobertura perfeita costuma indicar intervalos excessivamente conservadores e inelásticos, incapazes de refletir a variabilidade diária. Deve-se notar, contudo, que a avaliação baseia-se em apenas 15 observações por cenário, limitando conclusões definitivas sobre a calibração estrita dos intervalos em longo prazo.

7 Discussão Crítica

A aplicação da metodologia de Box-Jenkins permitiu identificar o componente central da dinâmica de poluição diária. A principal vantagem do modelo ARMA(1,1) reside em sua parcimônia e capacidade de processar simultaneamente a inércia autorregressiva do poluente e a absorção de choques passados de curto prazo, culminando em uma representação parcimoniosa da média condicional.

Contudo, o arcabouço paramétrico linear demonstrou limitações marcantes quanto à mensuração de risco. O modelo captura adequadamente a dinâmica média, mas falha em representar a variabilidade condicional. Essa insuficiência foi evidenciada empiricamente através da inércia dos intervalos de confiança nas previsões e referendada estatisticamente pela rejeição da normalidade no teste de Jarque-Bera e detecção de heterocedasticidade no teste ARCH-LM.

Para refinar a modelagem e acomodar a incerteza ambiental de forma realista, sugere-se:

- A substituição da premissa de variância constante por modelos GARCH (como o EGARCH) (3), adequados para absorver a volatilidade agrupada e o impacto climático assimétrico.
- A adoção de distribuições de caudas pesadas (como a *t-Student* assimétrica ou *sGED*) para os resíduos, adequando-se aos extremos climáticos e abandonando a distribuição Gaussiana.
- A expansão para modelos multivariados (ARMAX), incorporando covariáveis exógenas como temperatura e velocidade do vento, que influenciam a dispersão do material particulado atmosférico.

8 Conclusão

Este trabalho alcançou o objetivo de modelar e analisar a dinâmica de concentração diária de material particulado (PM2.5) na cidade de Pequim através do rigor da metodologia clássica de séries temporais. As transformações aplicadas e o procedimento de seleção via Critério de Informação de Akaike culminaram na especificação de um modelo ARMA(1,1). Esse processo mostrou-se efetivo para modelar a dinâmica média da série, propiciando previsões pontuais adequadas e eliminando evidências de autocorrelação linear residual.

Não obstante, a exploração diagnóstica aprofundada evidenciou a fragilidade de premissas estáticas frente a instabilidades climáticas extremas. A principal limitação reside na subestimação da variância condicional durante períodos sazonais de alta volatilidade, limitando a acurácia dos intervalos de confiança. Como direcionamento futuro, conclui-se que o acoplamento de modelagens heterocedásticas e multivariadas

constitui uma direção promissora para aprimoramento metodológico na formulação de alertas meteorológicos e políticas de saúde pública mais acuradas.

Referências

[1] Burnham, K. P., & Anderson, D. R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach* (2nd ed.). Springer.

[2] Liang, X., Zou, T., Guo, B., Li, S., Zhang, H., Zhang, S., Huang, H., & Chen, S. X. (2015). Assessing beijing's pm2.5 pollution: challenges and solutions. *Journal of Geophysical Research: Atmospheres*, 120(21), 11311-11328.

[3] Morettin, P. A., & Toloi, C. M. C. (2018). *Análise de Séries Temporais* (3rd ed.). Blucher.

[4] R Core Team. (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing.